## Local 模式

所谓的 Local 模式,就是不需要其他任何节点资源就可以在本地执行 Spark 代码的环境。

## 解压缩文件

将 spark-3.0.0-bin-hadoop3.2.tgz 文件上传到 Linux 并解压缩,放置在指定位置,路径中不要包含中文或空格。

```
tar -zxvf spark-3.0.0-bin-hadoop3.2.tgz -C /opt/module
cd /opt/module
mv spark-3.0.0-bin-hadoop3.2 spark-local
```

#### 启动 Local 环境

1. 进入解压缩后的路径, 执行如下指令

```
bin/spark-shell
```

2. 启动成功后,可以输入网址进行 Web UI 监控页面访问http://虚拟机地址:4040

## 命令行工具

在解压缩文件夹下的 data 目录中,添加 word.txt 文件。在命令行工具中执行如下代码指令(和 IDEA 中代码简化版一致)

```
sc.textFile("data/word.txt").flatMap(_.split(" ")).map((_,1)).reduceByKey(_+_).collect
```

### 退出本地模式

按键 Ctrl+C 或输入 Scala 指令

```
:quit
```

#### 提交应用

```
bin/spark-submit \
--class org.apache.spark.examples.SparkPi \
--master local[2] \
./examples/jars/spark-examples_2.12-3.0.0.jar \
10
```

- 1. --class 表示要执行程序的主类,此处可以更换为咱们自己写的应用程序
- 2. --master local[2] 部署模式,默认为本地模式,数字表示分配的虚拟 CPU 核数量
- 3. spark-examples\_2.12-3.0.0.jar 运行的应用类所在的 jar 包,实际使用时,可以设定为自己打的 jar 包
- 4. 数字 10 表示程序的入口参数,用于设定当前应用的任务数量

# Standalone 模式

将应用提交到对应的集群中去执行,只使用 Spark 自身节点运行的集群模式,也就是所谓的 独立部署 (Standalone) 模式。

Spark 的 Standalone 模式体现了经典的 master-slave 模式。

#### 解压缩文件

将 spark-3.0.0-bin-hadoop3.2.tgz 文件上传到 Linux 并解压缩在指定位置

```
tar -zxvf spark-3.0.0-bin-hadoop3.2.tgz -C /opt/module
cd /opt/module
mv spark-3.0.0-bin-hadoop3.2 spark-standalone
```

#### 修改配置文件

1. 进入解压缩后路径的 conf 目录, 修改 slaves.template 文件名为 slaves

```
mv slaves.template slaves
```

2. 修改 slaves 文件,添加 work 节点

```
linux1
linux2
linux3
```

3. 修改 spark-env.sh.template 文件名为 spark-env.sh

```
mv spark-env.sh.template spark-env.sh
```

4. 修改 spark-env.sh 文件,添加 JAVA\_HOME 环境变量和集群对应的 master 节点

```
export JAVA_HOME=/opt/module/jdk1.8.0_144
SPARK_MASTER_HOST=linux1
SPARK_MASTER_PORT=7077

# 注意: 7077 端口,相当于 hadoop3 内部通信的 8020 端口,此处的端口需要确认自己的 Hadoop 配置
```

```
xsync spark-standalone
```

## 提交应用

```
bin/spark-submit \
--class org.apache.spark.examples.SparkPi \
--master spark://linux1:7077 \
./examples/jars/spark-examples_2.12-3.0.0.jar \
10
```

- 1. --class 表示要执行程序的主类
- 2. --master spark://linux1:7077 独立部署模式,连接到 Spark 集群
- 3. spark-examples\_2.12-3.0.0.jar 运行类所在的 jar 包
- 4. 数字 10 表示程序的入口参数,用于设定当前应用的任务数量

```
# 提交参数说明
# 在提交应用中,一般会同时一些提交参数
bin/spark-submit \
--class <main-class>
--master <master-url> \
... # other options
<application-jar> \
[application-arguments]
```

参数	解释	可选值举例	
class	Spark 程序中包含主函数的类		
master	Spark 程序运行的模式(环境)	模式: local[*]、spark://linux1:7077、	
		Yarn	
executor-memory 1G	指定每个 executor 可用内存为 1G	符合集群内存配置即可,具体情况具体分	
total-executor-cores 2	指定所有 executor 使用的 cpu 核数	析。	
	为2个		
executor-cores	指定每个executor使用的cpu核数		
application-jar	打包好的应用 jar, 包含依赖。这		
	个 URL 在集群中全局可见。 比		
	如 hdfs:// 共享存储系统,如果是		
	file:// path, 那么所有的节点的		
	path 都包含同样的 jar		
application-arguments	传给 main()方法的参数		

#### 配置历史服务

由于 spark-shell 停止掉后,集群监控 linux 1:4040 页面就看不到历史任务的运行情况,所以开发时都配置历史服务器记录任务运行情况。

1. 修改 spark-defaults.conf.template 文件名为 spark-defaults.conf

```
mv spark-defaults.conf.template spark-defaults.conf
```

2. 修改 spark-default.conf 文件,配置日志存储路径

```
spark.eventLog.enabled true
spark.eventLog.dir hdfs://linux1:8020/directory
```

# 注意: 需要启动 hadoop 集群, HDFS 上的 directory 目录需要提前存在。

3. 修改 spark-env.sh 文件, 添加日志配置

```
export SPARK_HISTORY_OPTS="
-Dspark.history.ui.port=18080
-Dspark.history.fs.logDirectory=hdfs://linux1:8020/directory
-Dspark.history.retainedApplications=30"
```

参数 1 含义: WEB UI 访问的端口号为 18080

参数 2 含义: 指定历史服务器日志存储路径

参数 3 含义: 指定保存 Application 历史记录的个数,如果超过这个值,旧的应用程序信息将被删除,这个是内存中的应用数,而不是页面上显示的应用数。

4. 分发配置文件

xsync conf

5. 重新启动集群和历史服务

sbin/start-all.sh sbin/start-history-server.sh

# 配置高可用 (HA)

所谓的高可用是因为当前集群中的 Master 节点只有一个,所以会存在单点故障问题。所以 为了解决单点故障问题,需要在集群中配置多个 Master 节点,一旦处于活动状态的 Master 发生故障时,由备用 Master 提供服务,保证作业可以继续执行。这里的高可用一般采用 Zookeeper 设置

1. 停止集群

sbin/stop-all.sh

2. 启动 Zookeeper

xstart zk

- 3. 修改 spark-env.sh 文件添加如下配置
  - # 注释如下内容:
  - # SPARK\_MASTER\_HOST=linux1
  - # SPARK\_MASTER\_PORT=7077
  - #添加如下内容:
  - # Master 监控页面默认访问端口为 8080, 但是可能会和 Zookeeper 冲突,所以改成 8989, 也可以自定义,访问 UI 监控页面时请注意

SPARK\_MASTER\_WEBUI\_PORT=8989

export SPARK\_DAEMON\_JAVA\_OPTS="

- -Dspark.deploy.recoveryMode=ZOOKEEPER
- -Dspark.deploy.zookeeper.url=linux1,linux2,linux3
- -Dspark.deploy.zookeeper.dir=/spark"
- 4. 分发配置文件

xsync conf/

5. 启动集群

sbin/start-all.sh

## Yarn 模式

独立部署 (Standalone) 模式由 Spark 自身提供计算资源,无需其他框架提供资源。这种方式降低了和其他第三方资源框架的耦合性,独立性非常强。Spark 主要是计算框架,而不是资源调度框架,所以本身提供的资源调度并不是它的强项,所以还是和其他专业的资源调度框架集成会更靠谱一些。

## 解压缩文件

将 spark-3.0.0-bin-hadoop3.2.tgz 文件上传到 linux 并解压缩,放置在指定位置。

```
tar -zxvf spark-3.0.0-bin-hadoop3.2.tgz -C /opt/module
cd /opt/module
mv spark-3.0.0-bin-hadoop3.2 spark-yarn
```

#### 修改配置文件

1. 修改 hadoop 配置文件/opt/module/hadoop/etc/hadoop/yarn-site.xml, 并分发

2. 修改 conf/spark-env.sh, 添加 JAVA\_HOME 和 YARN\_CONF\_DIR 配置

```
mv spark-env.sh.template spark-env.sh
export JAVA_HOME=/opt/module/jdk1.8.0_144
YARN_CONF_DIR=/opt/module/hadoop/etc/hadoop
# 启动 HDFS 以及 YARN 集群,启动
```

#### 提交应用

```
bin/spark-submit \
--class org.apache.spark.examples.SparkPi \
--master yarn \
--deploy-mode cluster \
./examples/jars/spark-examples_2.12-3.0.0.jar \
10
```

#### 配置历史服务器

1. 修改 spark-defaults.conf.template 文件名为 spark-defaults.conf

```
mv spark-defaults.conf.template spark-defaults.conf
```

2. 修改 spark-default.conf 文件,配置日志存储路径

```
spark.eventLog.enabled true
spark.eventLog.dir hdfs://linux1:8020/directory
```

注意: 需要启动 hadoop 集群, HDFS 上的目录需要提前存在。

```
sbin/start-dfs.sh
hadoop fs -mkdir /directory
```

3. 修改 spark-env.sh 文件, 添加日志配置

```
export SPARK_HISTORY_OPTS="
-Dspark.history.ui.port=18080
-Dspark.history.fs.logDirectory=hdfs://linux1:8020/directory
-Dspark.history.retainedApplications=30"
```

```
参数 1 含义: WEB UI 访问的端口号为 18080
参数 2 含义: 指定历史服务器日志存储路径
参数 3 含义: 指定保存 Application 历史记录的个数,如果超过这个值,旧的应用程序
信息将被删除,这个是内存中的应用数,而不是页面上显示的应用数。
```

4. 修改 spark-defaults.conf

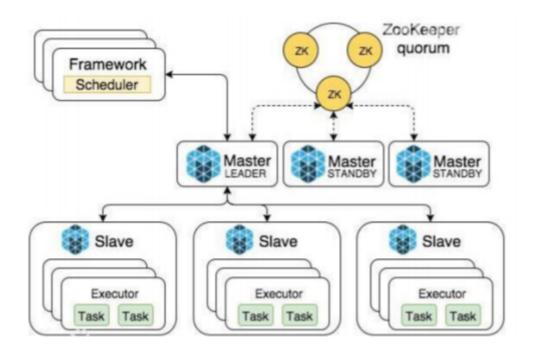
```
spark.yarn.historyServer.address=linux1:18080
spark.history.ui.port=18080
```

5. 启动历史服务

```
sbin/start-history-server.sh
```

## K8S & Mesos 模式;

Mesos 是 Apache 下的开源分布式资源管理框架,它被称为是分布式系统的内核,在 Twitter 得到广泛使用,管理着 Twitter 超过 30,0000 台服务器上的应用部署,但是在国内,依 然使用着传统的 Hadoop 大数据框架,所以国内使用 Mesos 框架的并不多,但是原理其实都差不多。



容器化部署是目前业界很流行的一项技术,基于 Docker 镜像运行能够让用户更加方便 地对应用进行管理和运维。容器管理工具中最为流行的就是 Kubernetes(k8s),而 Spark 也在最近的版本中支持了 k8s 部署模式。

